



# Введение

В рамках НИР будет решаться задача **классификации**: будем предсказывать, **заработает ли человек более 50K\$/год** (да/нет)

Используемый датасет: **Adult Income Dataset**

## Цели исследования

- Изучить структуру и особенности исходных данных
- Провести разведочный анализ (EDA) с построением графиков
- Провести корреляционный анализ
- Провести обработку данных (кодирование категориальных, масштабирование)
- Построить baseline модели, провести тюнинг гиперпараметров
- Сравнить качество моделей по различным метрикам
- Сделать итоговые выводы

## Импорт библиотек

```
In [3]: # Основные библиотеки
import time
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Для моделей
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import accuracy_score, f1_score, roc_auc_score, classification_report
from sklearn.metrics import RocCurveDisplay

# Модели
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.svm import SVC

# Прочее
import warnings
warnings.filterwarnings('ignore')
```

## Загрузка данных

```
In [4]: # Загрузка датасета
df = pd.read_csv('../data/adult.csv')

df.head()
```

```
Out[4]:
```

	age	workclass	fnlwgt	education	education.num	marital.status	occupation
0	90	?	77053	HS-grad	9	Widowed	
1	82	Private	132870	HS-grad	9	Widowed	Exec manageria
2	66	?	186061	Some- college	10	Widowed	
3	54	Private	140359	7th-8th	4	Divorced	Machine-op inspc
4	41	Private	264663	Some- college	10	Separated	Pro specialt

## Разведочный анализ данных

### Описание данных

```
In [5]: # Основная информация
df.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 32561 entries, 0 to 32560
Data columns (total 15 columns):
#   Column                Non-Null Count  Dtype
---  -
0   age                   32561 non-null  int64
1   workclass             32561 non-null  object
2   fnlwgt                32561 non-null  int64
3   education             32561 non-null  object
4   education.num         32561 non-null  int64
5   marital.status        32561 non-null  object
6   occupation            32561 non-null  object
7   relationship          32561 non-null  object
8   race                  32561 non-null  object
9   sex                   32561 non-null  object
10  capital.gain          32561 non-null  int64
11  capital.loss          32561 non-null  int64
12  hours.per.week        32561 non-null  int64
13  native.country        32561 non-null  object
14  income                32561 non-null  object
dtypes: int64(6), object(9)
memory usage: 3.7+ MB

```

## Проверка пропусков

```
In [6]: df.isnull().sum()
```

```

Out[6]: age                0
workclass                0
fnlwgt                   0
education                0
education.num            0
marital.status           0
occupation               0
relationship             0
race                     0
sex                      0
capital.gain             0
capital.loss             0
hours.per.week           0
native.country           0
income                   0
dtype: int64

```

## Статистика по данным

```
In [7]: df.describe().T
```

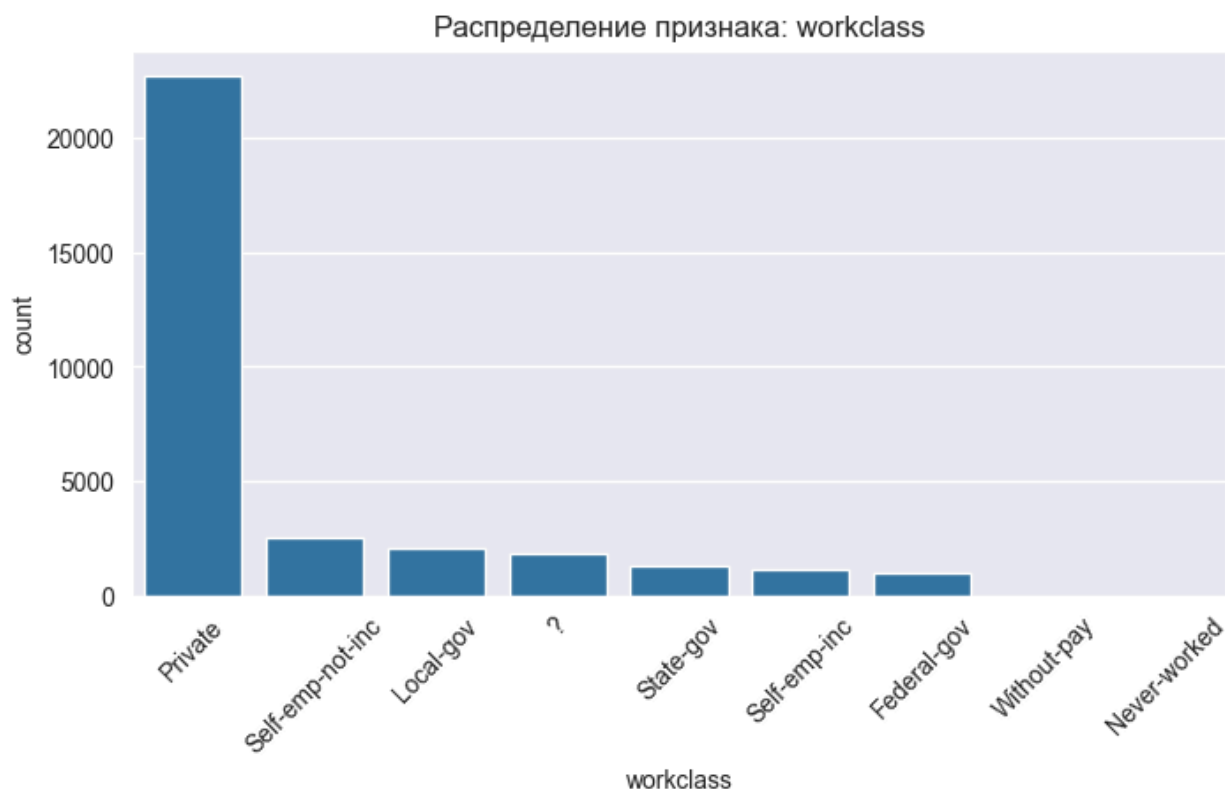
Out[7]:

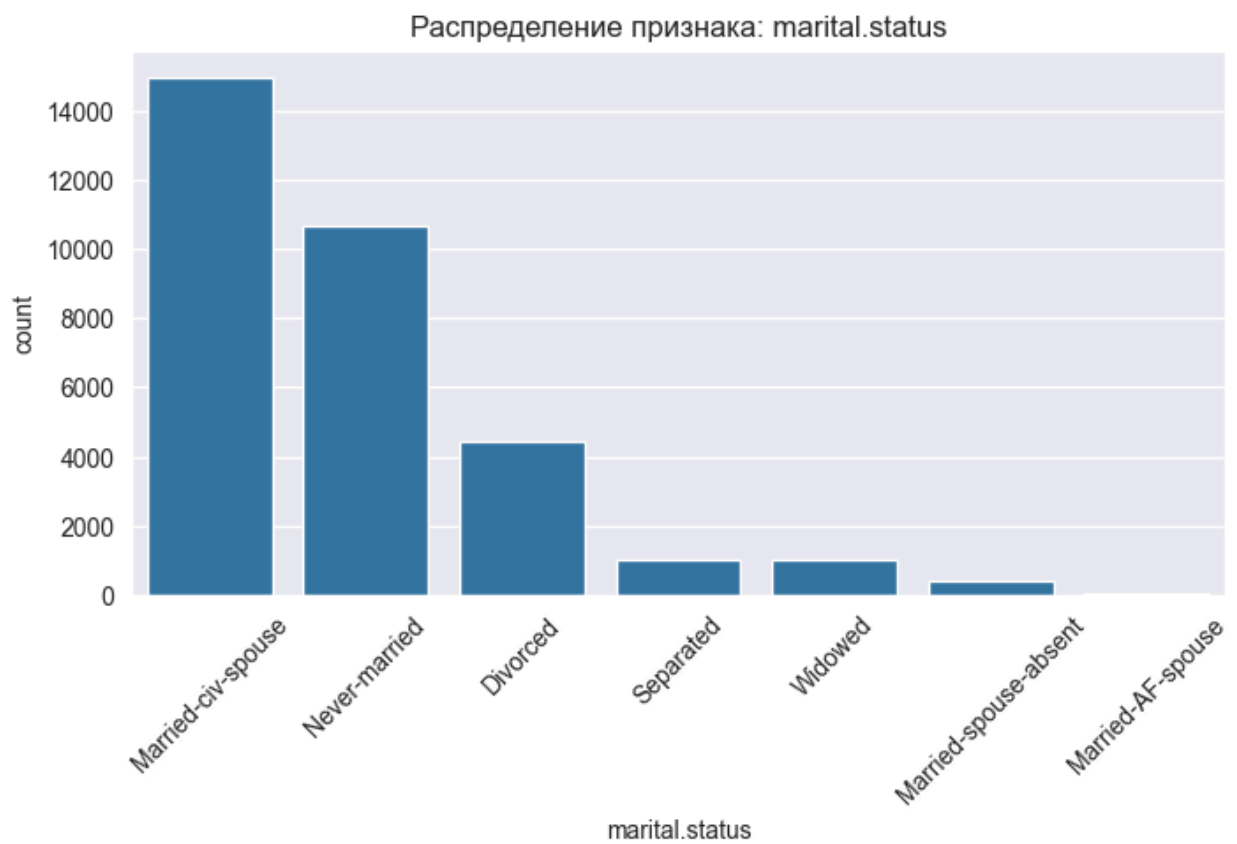
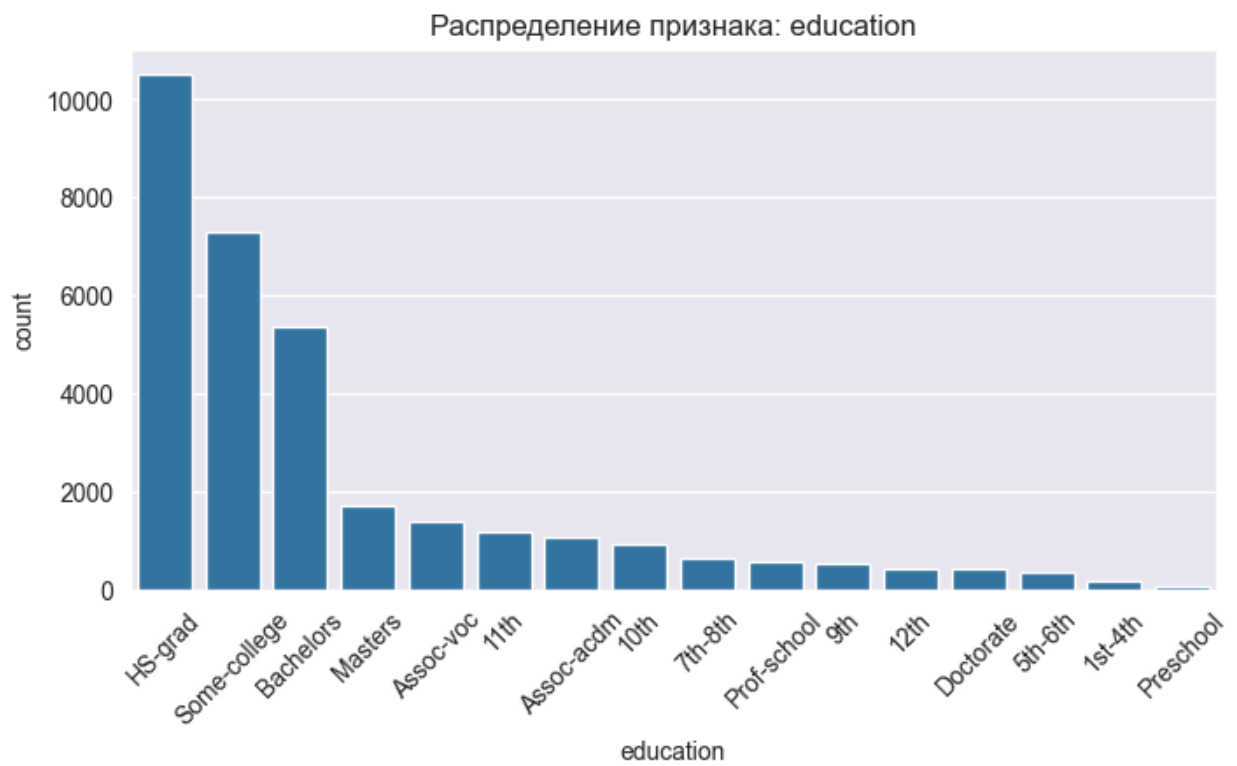
	count	mean	std	min	25%	50%
age	32561.0	38.581647	13.640433	17.0	28.0	36.0
fnlwgt	32561.0	189778.366512	105549.977697	12285.0	117827.0	178354.0
education.num	32561.0	10.080679	2.572720	1.0	9.0	12.0
capital.gain	32561.0	1077.648844	7385.292085	0.0	0.0	3921.0
capital.loss	32561.0	87.303830	402.960219	0.0	0.0	4199.0
hours.per.week	32561.0	40.437456	12.347429	1.0	40.0	45.0

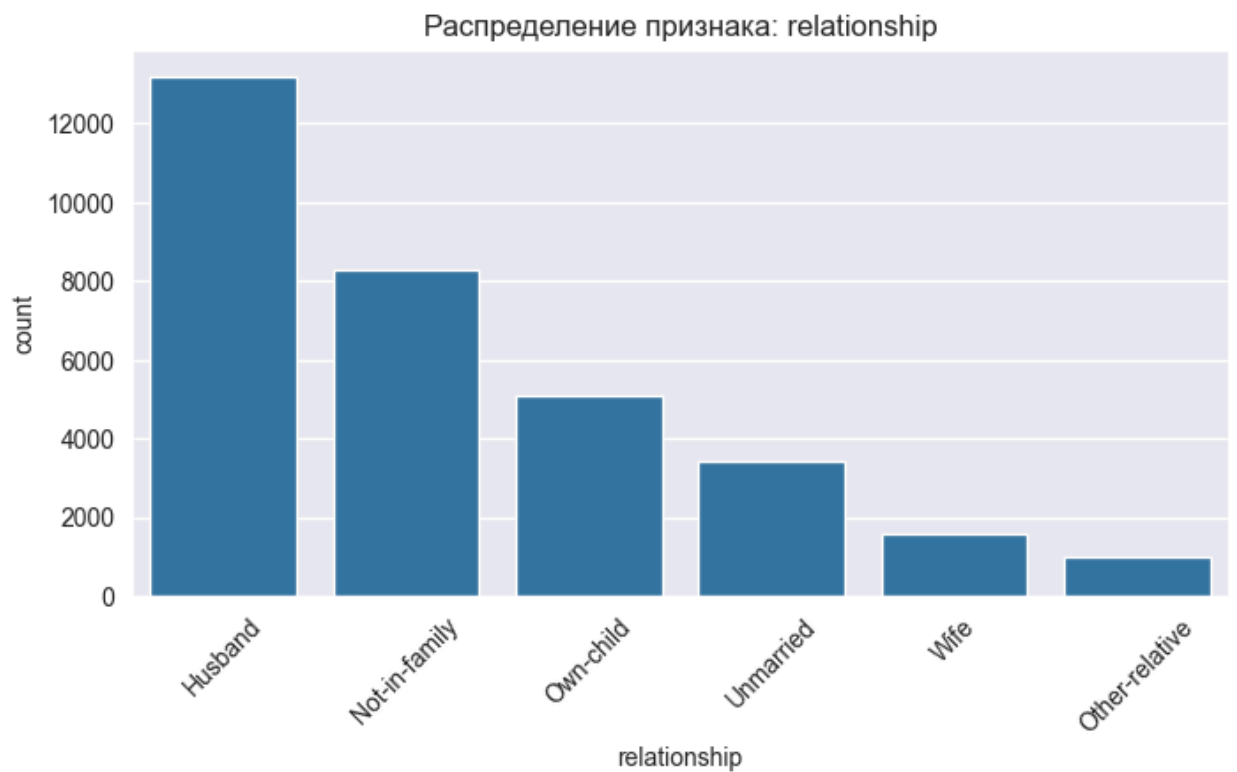
## Графики категориальных признаков

```
In [8]: # Категориальные признаки
cat_features = df.select_dtypes(include='object').columns.tolist()


for col in cat_features:
    plt.figure(figsize=(8,4))
    sns.countplot(data=df, x=col, order=df[col].value_counts().index)
    plt.title(f"Распределение признака: {col}")
    plt.xticks(rotation=45)
    plt.show()
```






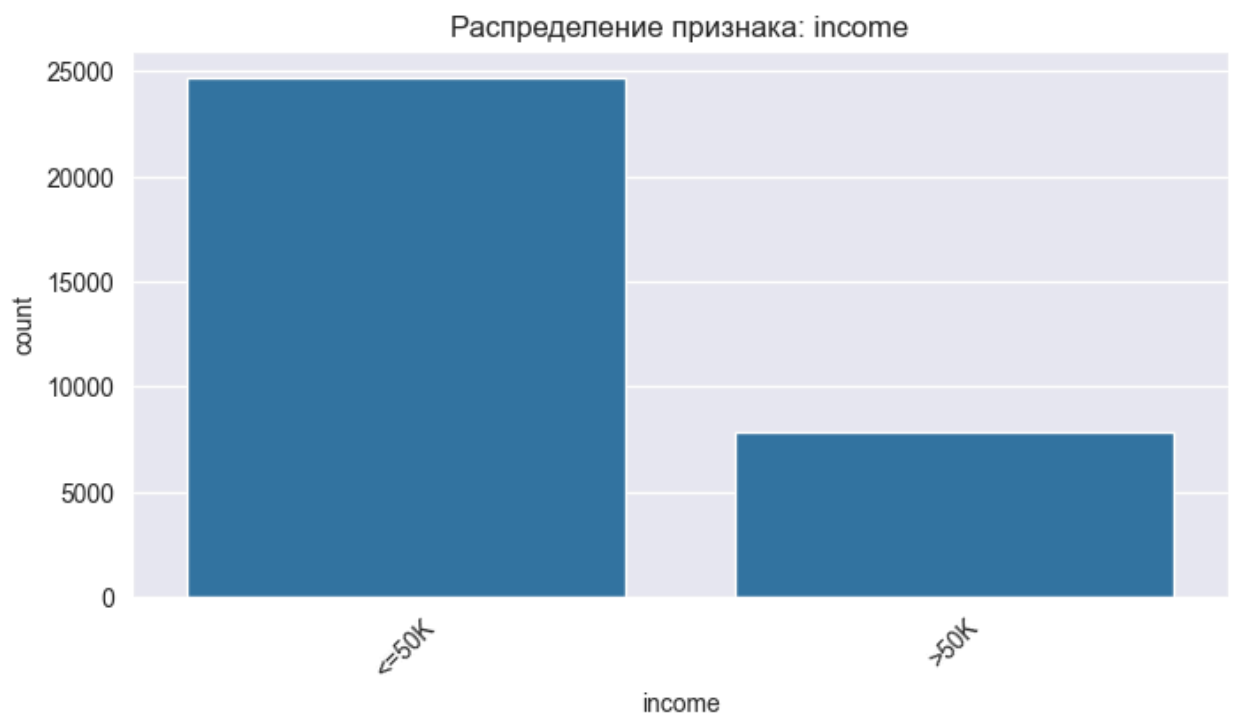



Распределение признака: race



Распределение признака: sex



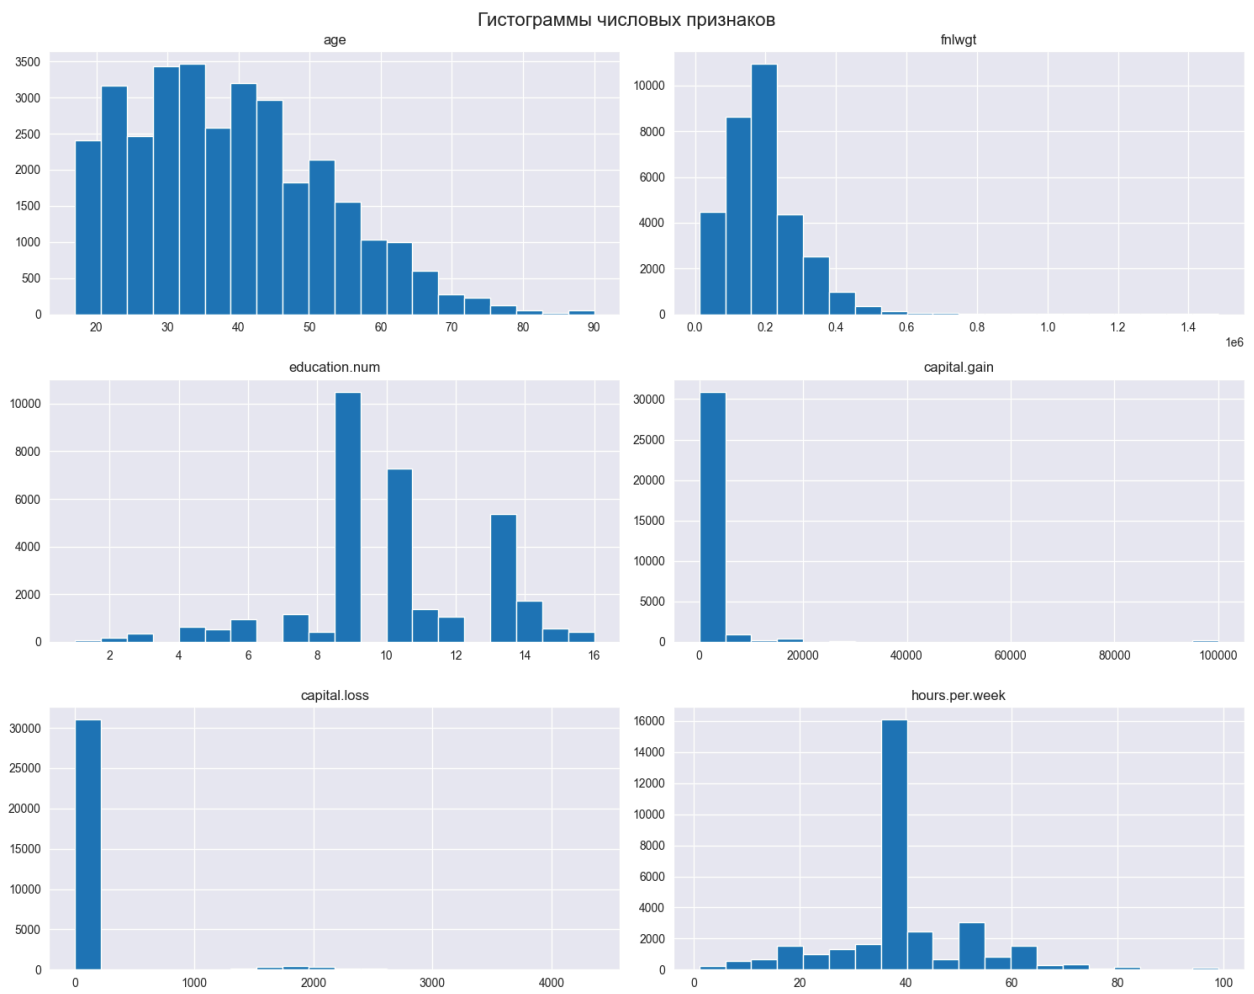


## Графики числовых признаков

```
In [9]: # Числовые признаки
num_features = df.select_dtypes(include=['int64', 'float64']).columns.tolist()
```



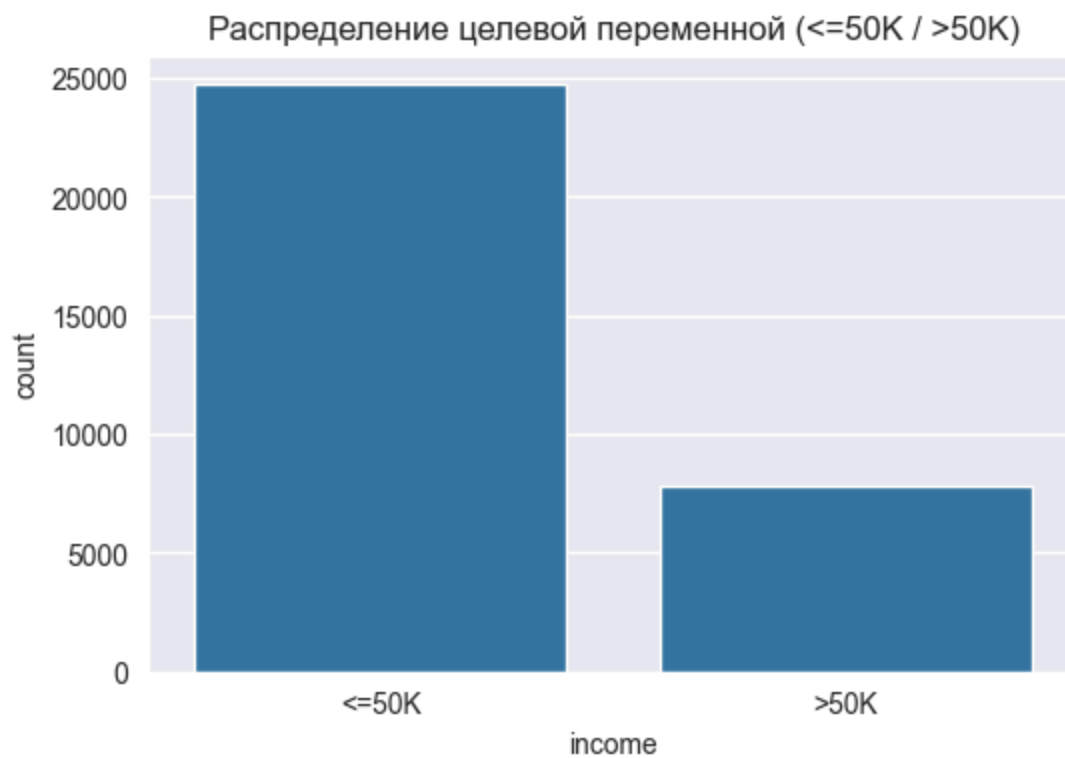
```
df[num_features].hist(figsize=(15,12), bins=20)
plt.suptitle("Гистограммы числовых признаков", fontsize=16)
plt.tight_layout()
plt.show()
```



## Анализ целевой переменной

```
In [10]: plt.figure(figsize=(6,4))
sns.countplot(x='income', data=df)
plt.title('Распределение целевой переменной (<=50K / >50K)')
plt.show()


df['income'].value_counts(normalize=True)
```



```
Out[10]: income
<=50K    0.75919
>50K     0.24081
Name: proportion, dtype: float64
```

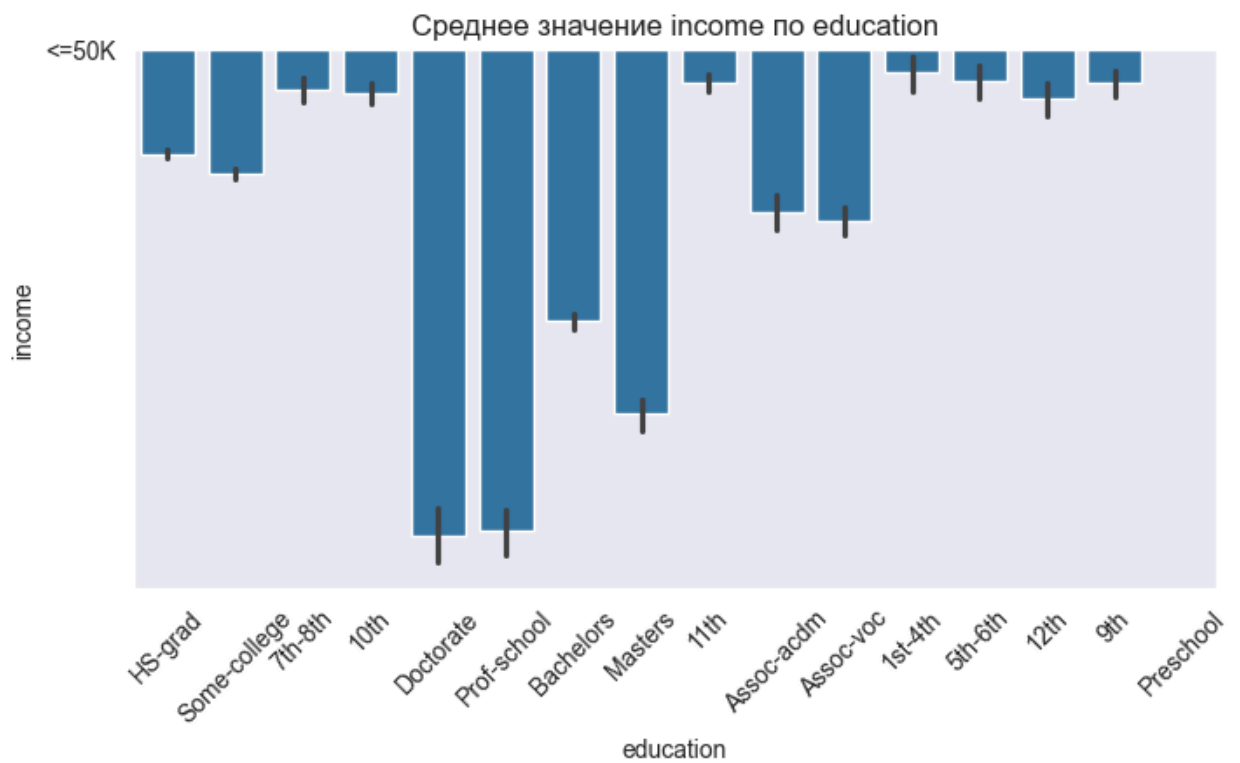
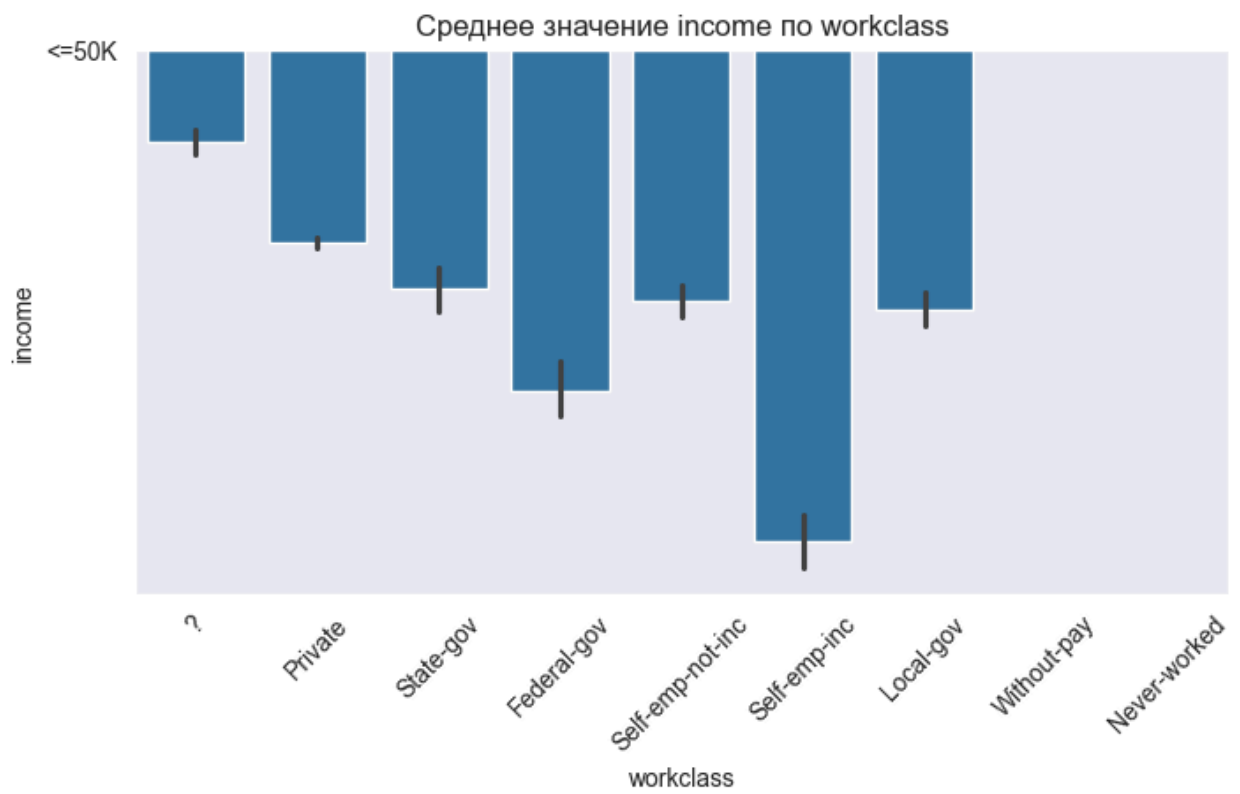
## Корреляционный анализ

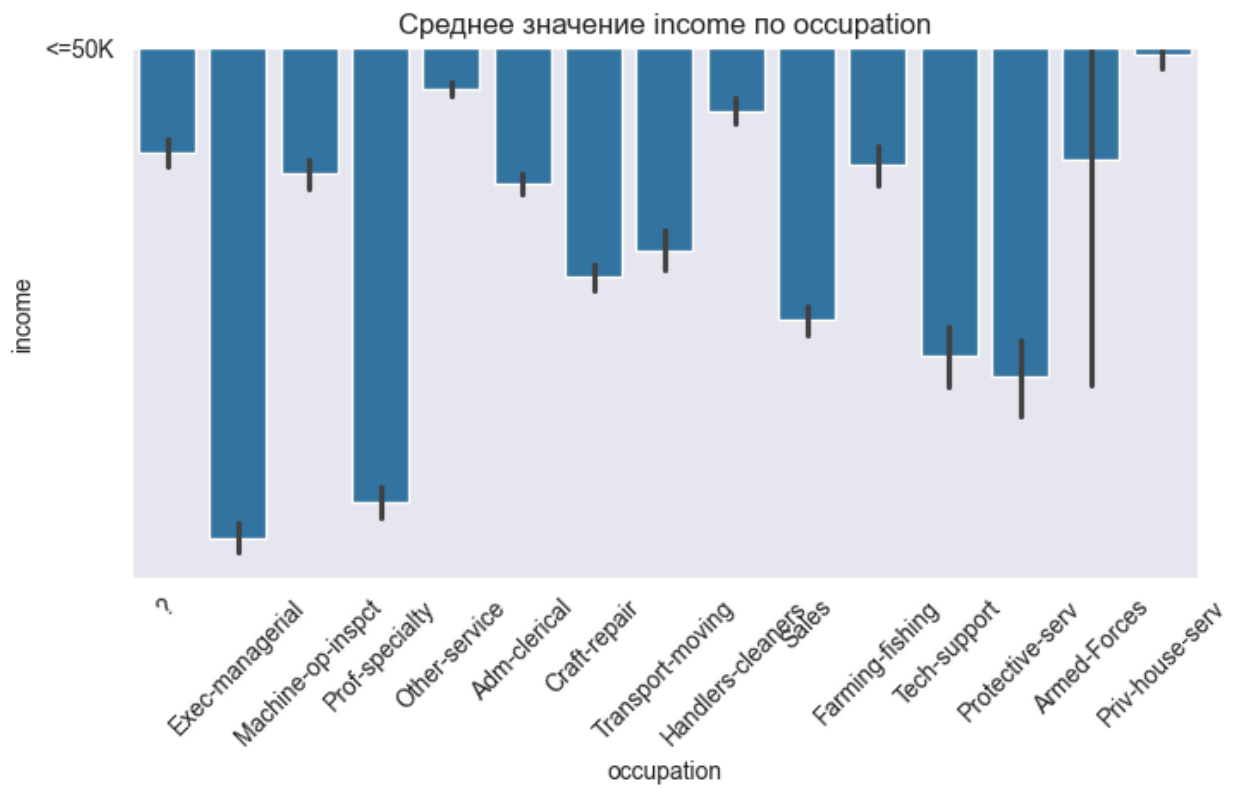
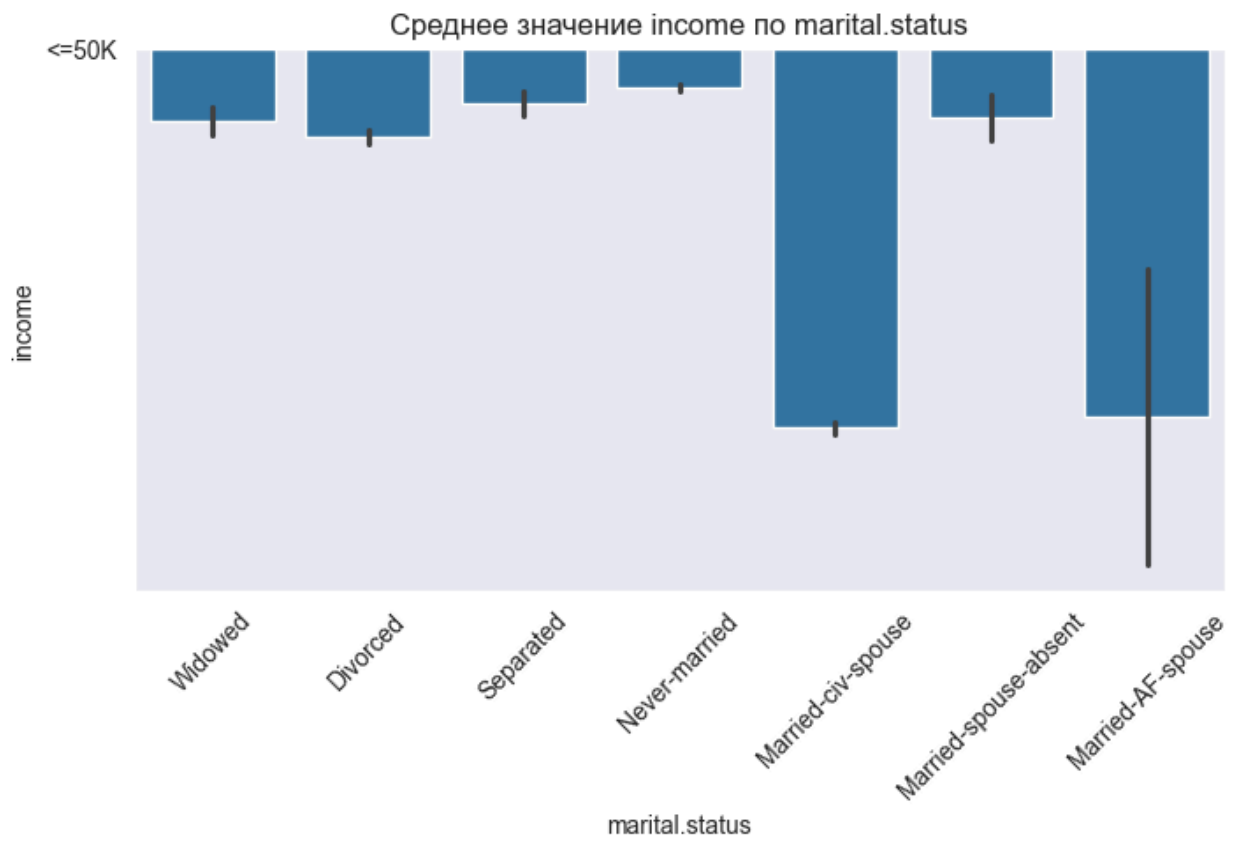
```
In [11]: # Для числовых признаков
plt.figure(figsize=(12,10))
sns.heatmap(df.corr(numeric_only=True), annot=True, fmt=".2f", cmap='coolwarm')
plt.title('Корреляционная матрица')
plt.show()
```

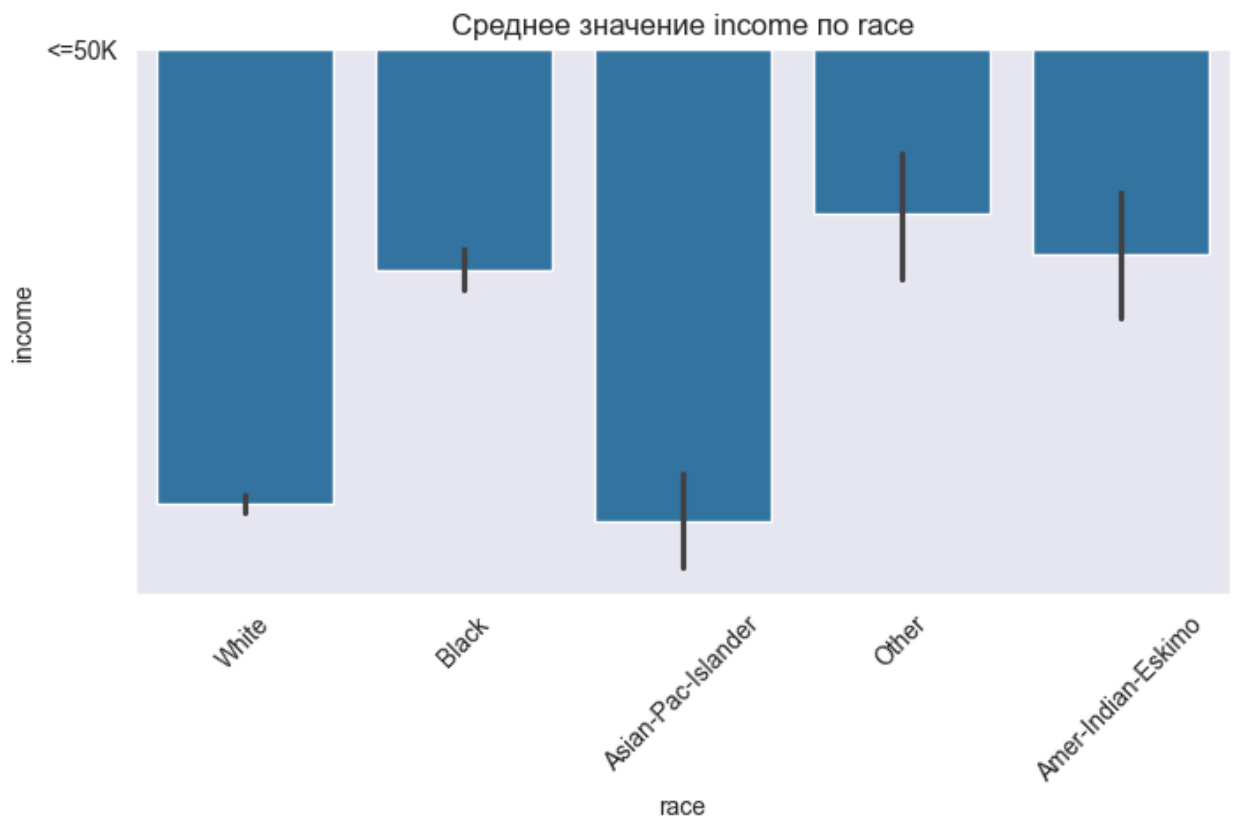
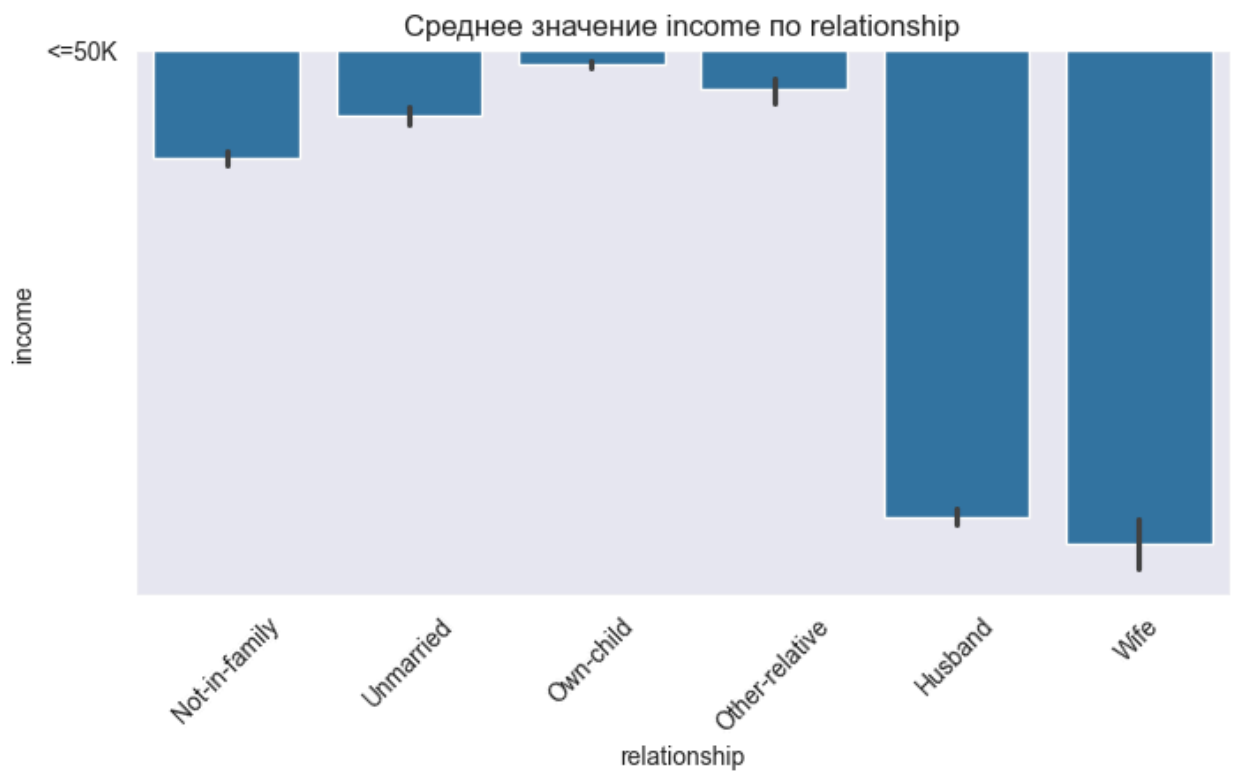



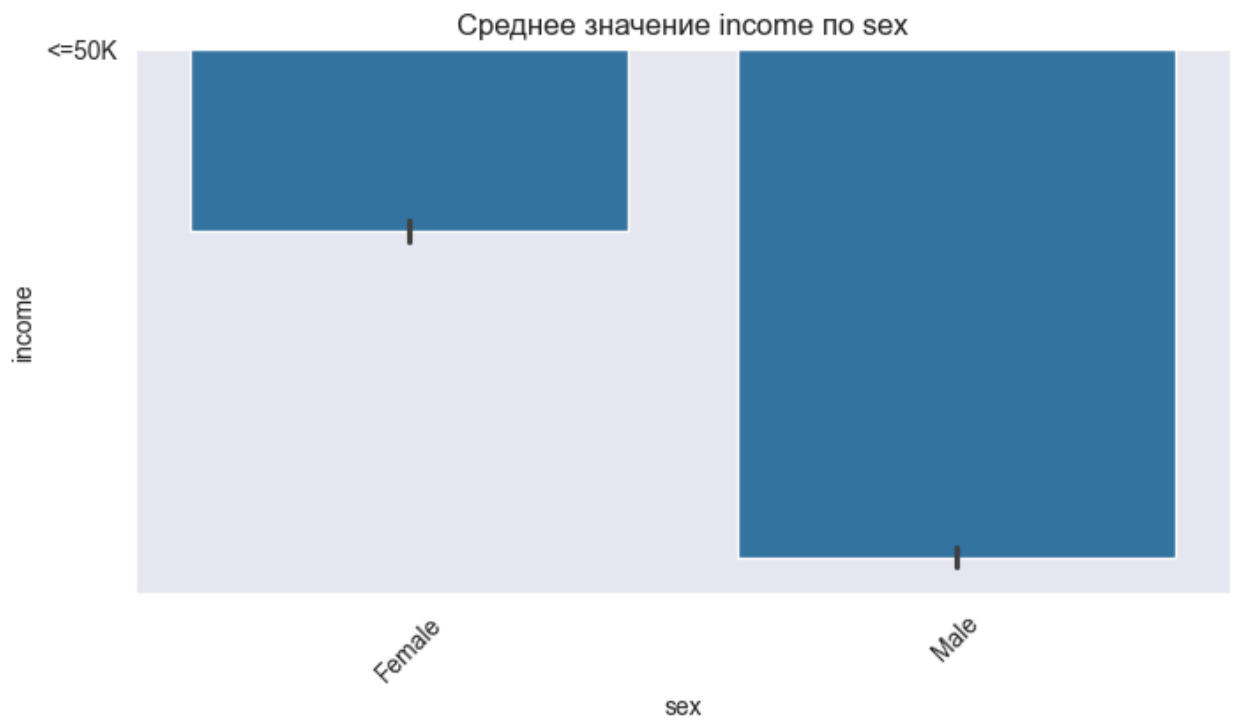
## Корреляция категориальных признаков с целевой переменной


```
In [12]: # Barplot категориальных признаков по income
for col in cat_features:
    plt.figure(figsize=(8,4))
    sns.barplot(x=col, y='income', data=df)
    plt.title(f"Среднее значение income по {col}")
    plt.xticks(rotation=45)
    plt.show()
```











## Выводы по разведочному анализу данных (EDA)

В результате проведённого разведочного анализа можно сделать следующие выводы:

### 1. Общая информация о данных

- Датасет содержит **~32 562** записей и **15 признаков**.
- Целевая переменная — `income` ( `<=50K` или `>50K` ), бинарная классификация.
- Признаки включают как числовые, так и категориальные переменные (пол, уровень образования, семейное положение, род деятельности и др.).

### 2. Пропуски в данных

- Пропуски изначально представлены строками `'?'` в некоторых категориальных признаках (например, `workclass`, `occupation`, `native-country` ).



### 3. Распределение целевой переменной

- Наблюдается **дисбаланс классов**:
  - ~**75-76%** записей — доход `<=50K` ;
  - ~**24-25%** записей — доход `>50K` .

Это важно учитывать при выборе метрик оценки качества моделей (например, F1-score и ROC AUC предпочтительнее одной Accuracy).

### 4. Распределение категориальных признаков

- По ряду категориальных признаков наблюдается **неравномерное распределение**:
  - `workclass` — преобладают категории `Private` , `Self-emp` , `Government` .
  - `education` — большая доля людей с уровнем образования `HS-grad` , `Some-college` , `Bachelors` .
  - `marital-status` — заметно выделяются `Married-civ-spouse` и `Never-married` .
  - `occupation` — наиболее распространены `Prof-specialty` , `Craft-repair` , `Exec-managerial` .
  - `native-country` — подавляющее большинство респондентов из **United-States**.

### 5. Распределение числовых признаков

- Признак `age` — распределён **неравномерно**, с пиком в диапазоне **30-40 лет**.
- Признак `hours-per-week` — основное количество людей работает **~40 часов в неделю**, но есть выбросы (работающие по 70-90 часов).
- Признак `capital-gain` и `capital-loss` — сильно **сдвинуты к 0**, т.к. большинство людей не имеет капитальных доходов/потерь.

### 6. Корреляционный анализ

- Признаки с наибольшей корреляцией с `income` (в абсолютных значениях):
  - `education-num` — положительная корреляция: более высокий уровень образования повышает вероятность

дохода >50K.

- `hours-per-week` — положительная корреляция.
  - `capital-gain` и `capital-loss` — также положительно связаны с высоким доходом.
  - `age` — слабая, но положительная корреляция.
- Мультиколлинеарность между числовыми признаками **не выявлена** — можно включать все признаки в модель.

## 7. Влияние категориальных признаков на доход

- Наибольшее влияние на вероятность высокого дохода оказывают:
  - `marital-status` — **женатые в официальном браке** заметно чаще имеют доход >50K.
  - `occupation` — такие профессии, как `Exec-managerial` и `Prof-specialty`, значительно повышают вероятность высокого дохода.
  - `education` — более высокий уровень образования даёт преимущество.
  - `sex` — мужчины в среднем чаще имеют доход >50K (по данным данного датасета).
  - `native-country` — респонденты из US чаще имеют высокий доход по сравнению с другими странами (но данных из других стран мало).

---

## Итоги

Датасет хорошо подходит для решения задачи бинарной классификации.

- Есть **важные и интерпретируемые признаки**, влияющие на доход.
  - Имеется **небольшой дисбаланс классов**, который следует учесть при выборе моделей и метрик.
  - После базовой предобработки датасет готов к дальнейшей подготовке данных (кодированию, масштабированию) и построению моделей.
-

# Подготовка данных

```
In [13]: # Заменяем пропуски
df.replace('?', pd.NA, inplace=True)
df.dropna(inplace=True)

# Кодирование целевой переменной
df['income'] = df['income'].apply(lambda x: 1 if '>50K' in x else 0)

# Кодирование категориальных признаков
df_encoded = pd.get_dummies(df.drop('income', axis=1), drop_first=True)

# Масштабирование
scaler = StandardScaler()
X_scaled = scaler.fit_transform(df_encoded)

# Целевая переменная
X = X_scaled
y = df['income']

# Деление на train/test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

## Baseline модели

```
In [14]: from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.metrics import accuracy_score, f1_score, roc_auc_score

# Словарь для хранения результатов
results = {}

# Logistic Regression
lr = LogisticRegression()
lr.fit(X_train, y_train)
y_pred_lr = lr.predict(X_test)
results['Logistic Regression'] = [
    accuracy_score(y_test, y_pred_lr),
    f1_score(y_test, y_pred_lr),
    roc_auc_score(y_test, lr.predict_proba(X_test)[:,1])
]

# Decision Tree
tree = DecisionTreeClassifier(random_state=42)
tree.fit(X_train, y_train)
y_pred_tree = tree.predict(X_test)
results['Decision Tree'] = [
```

```

accuracy_score(y_test, y_pred_tree),
f1_score(y_test, y_pred_tree),
roc_auc_score(y_test, tree.predict_proba(X_test)[: ,1])
]

# K-Nearest Neighbors
knn = KNeighborsClassifier(n_neighbors=5)
knn.fit(X_train, y_train)
y_pred_knn = knn.predict(X_test)
results['KNN'] = [
    accuracy_score(y_test, y_pred_knn),
    f1_score(y_test, y_pred_knn),
    roc_auc_score(y_test, knn.predict_proba(X_test)[: ,1])
]

# Random Forest
rf = RandomForestClassifier(random_state=42)
rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)
results['Random Forest'] = [
    accuracy_score(y_test, y_pred_rf),
    f1_score(y_test, y_pred_rf),
    roc_auc_score(y_test, rf.predict_proba(X_test)[: ,1])
]

# Gradient Boosting
gb = GradientBoostingClassifier(random_state=42)
gb.fit(X_train, y_train)
y_pred_gb = gb.predict(X_test)
results['Gradient Boosting'] = [
    accuracy_score(y_test, y_pred_gb),
    f1_score(y_test, y_pred_gb),
    roc_auc_score(y_test, gb.predict_proba(X_test)[: ,1])
]

```

```

In [15]: # Оформим результаты в таблицу
results_df = pd.DataFrame(results, index=['Accuracy', 'F1-score', 'ROC AUC']).
results_df = results_df.sort_values(by='F1-score', ascending=False) # сортиру
results_df.style.background_gradient(cmap='Blues').format("{:.4f}")

```

Out[15]:

	Accuracy	F1-score	ROC AUC
Gradient Boosting	0.8596	0.6838	0.9158
Random Forest	0.8424	0.6568	0.8961
Logistic Regression	0.8420	0.6528	0.8970
Decision Tree	0.8037	0.6143	0.7452
KNN	0.8147	0.6016	0.8313

	Accuracy	F1-score	ROC AUC
<b>Gradient Boosting</b>	0.8596	0.6838	0.9158
<b>Random Forest</b>	0.8424	0.6568	0.8961
<b>Logistic Regression</b>	0.8420	0.6528	0.8970
<b>Decision Tree</b>	0.8037	0.6143	0.7452
<b>KNN</b>	0.8147	0.6016	0.8313

# Выводы по baseline моделям

По итогам оценки пяти baseline моделей машинного обучения на основе метрик Accuracy, F1-score и ROC AUC можно сделать следующие выводы:

**Gradient Boosting** показал наилучшее качество классификации по всем трём метрикам:

- Accuracy: **0.8596**
- F1-score: **0.6838**
- ROC AUC: **0.9158**

Это делает его основным кандидатом для последующего подбора гиперпараметров и использования в финальной модели.

**Random Forest** и **Logistic Regression** продемонстрировали сопоставимые результаты:

- F1-score у обеих моделей находится на уровне **0.65**, при этом ROC AUC > 0.89, что указывает на хорошее качество ранжирования.
- Accuracy находится на уровне **0.842**, что подтверждает стабильность классификации.

**Decision Tree** и **K-Nearest Neighbors** показали худшие результаты:

- Decision Tree страдает от переобучения и нестабильности (Accuracy: 0.8037, F1: 0.6143).
- KNN даёт низкий F1-score (**0.6016**), вероятно, из-за высокой чувствительности к масштабированию и размеру выборки.

---

## Промежуточный вывод:

- Лучшими по совокупности метрик являются **ансамблевые модели** (Gradient Boosting и Random Forest).
  - В дальнейшем будет произведён **подбор гиперпараметров** для этих моделей с целью повышения их эффективности.
  - Также рекомендуется рассмотреть использование методов балансировки классов, если потребуется повысить F1-score ещё сильнее.
-

# Подбор гиперпараметров

## GridSearch для GradientBoostingClassifier

```
In [16]: from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import GradientBoostingClassifier, RandomForestClassifier
from sklearn.metrics import accuracy_score, f1_score, roc_auc_score
import time

# Сетка параметров
param_grid_gb = {
    'n_estimators': [100, 200],
    'max_depth': [3, 5, 7],
    'learning_rate': [0.1, 0.05],
    'min_samples_split': [2, 5]
}

gb = GradientBoostingClassifier(random_state=42)

grid_search_gb = GridSearchCV(
    estimator=gb,
    param_grid=param_grid_gb,
    scoring='f1',
    cv=5,
    n_jobs=-1,
    verbose=1
)

# Подбор
start = time.time()
grid_search_gb.fit(X_train, y_train)
print(f"Время подбора GB: {time.time() - start:.2f} сек.")
print("Лучшие параметры GB:", grid_search_gb.best_params_)
print("Лучший F1-score (CV) GB:", grid_search_gb.best_score_)

# Оценка на тесте
best_gb = grid_search_gb.best_estimator_
y_pred_best_gb = best_gb.predict(X_test)

print("Test Accuracy GB:", accuracy_score(y_test, y_pred_best_gb))
print("Test F1-score GB:", f1_score(y_test, y_pred_best_gb))
print("Test ROC AUC GB:", roc_auc_score(y_test, best_gb.predict_proba(X_test))
```

Fitting 5 folds for each of 24 candidates, totalling 120 fits

Время подбора GB: 140.73 сек.

Лучшие параметры GB: {'learning\_rate': 0.1, 'max\_depth': 5, 'min\_samples\_split': 5, 'n\_estimators': 200}

Лучший F1-score (CV) GB: 0.7181838499362507

Test Accuracy GB: 0.8642466434609647

Test F1-score GB: 0.7040115648717022

Test ROC AUC GB: 0.9231230972865652

## GridSearch для RandomForestClassifier

```
In [17]: # Сетка параметров
param_grid_rf = {
    'n_estimators': [100, 200, 300],
    'max_depth': [None, 10, 20],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4]
}

rf = RandomForestClassifier(random_state=42)

grid_search_rf = GridSearchCV(
    estimator=rf,
    param_grid=param_grid_rf,
    scoring='f1',
    cv=5,
    n_jobs=-1,
    verbose=1
)

# Подбор
start = time.time()
grid_search_rf.fit(X_train, y_train)
print(f"Время подбора RF: {time.time() - start:.2f} сек.")
print("Лучшие параметры RF:", grid_search_rf.best_params_)
print("Лучший F1-score (CV) RF:", grid_search_rf.best_score_)

# Оценка на тесте
best_rf = grid_search_rf.best_estimator_
y_pred_best_rf = best_rf.predict(X_test)

print("Test Accuracy RF:", accuracy_score(y_test, y_pred_best_rf))
print("Test F1-score RF:", f1_score(y_test, y_pred_best_rf))
print("Test ROC AUC RF:", roc_auc_score(y_test, best_rf.predict_proba(X_test))
```

Fitting 5 folds for each of 81 candidates, totalling 405 fits

Время подбора RF: 101.21 сек.

Лучшие параметры RF: {'max\_depth': None, 'min\_samples\_leaf': 1, 'min\_samples\_split': 10, 'n\_estimators': 300}

Лучший F1-score (CV) RF: 0.6914793837327153

Test Accuracy RF: 0.8557931377424167

Test F1-score RF: 0.6794399410464259

Test ROC AUC RF: 0.9076996838002794

## GridSearch для LogisticRegression

```
In [18]: from sklearn.linear_model import LogisticRegression

param_grid_lr = {
    'C': [0.01, 0.1, 1, 10, 100],
```

```

        'penalty': ['l2'],
        'solver': ['lbfgs']
    }

    lr = LogisticRegression(random_state=42, max_iter=1000)

    grid_search_lr = GridSearchCV(
        estimator=lr,
        param_grid=param_grid_lr,
        scoring='f1',
        cv=5,
        n_jobs=-1,
        verbose=1
    )

    grid_search_lr.fit(X_train, y_train)

    print("Лучшие параметры LR:", grid_search_lr.best_params_)
    print("Лучший F1-score (CV) LR:", grid_search_lr.best_score_)

    best_lr = grid_search_lr.best_estimator_
    y_pred_best_lr = best_lr.predict(X_test)

    print("Test Accuracy LR:", accuracy_score(y_test, y_pred_best_lr))
    print("Test F1-score LR:", f1_score(y_test, y_pred_best_lr))
    print("Test ROC AUC LR:", roc_auc_score(y_test, best_lr.predict_proba(X_test))

```

Fitting 5 folds for each of 5 candidates, totalling 25 fits  
 Лучшие параметры LR: {'C': 1, 'penalty': 'l2', 'solver': 'lbfgs'}  
 Лучший F1-score (CV) LR: 0.6690860140127831  
 Test Accuracy LR: 0.8420354715730151  
 Test F1-score LR: 0.6528233151183971  
 Test ROC AUC LR: 0.8970130156629165

## GridSearch для DesicionTreeCllsifier

```

In [19]: param_grid_tree = {
        'max_depth': [None, 5, 10, 20],
        'min_samples_split': [2, 5, 10],
        'min_samples_leaf': [1, 2, 4]
    }

    tree = DecisionTreeClassifier(random_state=42)

    grid_search_tree = GridSearchCV(
        estimator=tree,
        param_grid=param_grid_tree,
        scoring='f1',
        cv=5,
        n_jobs=-1,
        verbose=1
    )

```



```

grid_search_tree.fit(X_train, y_train)

print("Лучшие параметры Tree:", grid_search_tree.best_params_)
print("Лучший F1-score (CV) Tree:", grid_search_tree.best_score_)

best_tree = grid_search_tree.best_estimator_
y_pred_best_tree = best_tree.predict(X_test)

print("Test Accuracy Tree:", accuracy_score(y_test, y_pred_best_tree))
print("Test F1-score Tree:", f1_score(y_test, y_pred_best_tree))
print("Test ROC AUC Tree:", roc_auc_score(y_test, best_tree.predict_proba(X_test)

```

Fitting 5 folds for each of 36 candidates, totalling 180 fits

Лучшие параметры Tree: {'max\_depth': 10, 'min\_samples\_leaf': 4, 'min\_samples\_split': 10}

Лучший F1-score (CV) Tree: 0.6681655607536656

Test Accuracy Tree: 0.8506547323056523

Test F1-score Tree: 0.6596146581035134

Test ROC AUC Tree: 0.8943953967203471

## GridSearch для KNN

```

In [20]: param_grid_knn = {
    'n_neighbors': [3, 5, 7, 9, 11],
    'weights': ['uniform', 'distance']
}

knn = KNeighborsClassifier()

grid_search_knn = GridSearchCV(
    estimator=knn,
    param_grid=param_grid_knn,
    scoring='f1',
    cv=5,
    n_jobs=-1,
    verbose=1
)

grid_search_knn.fit(X_train, y_train)

print("Лучшие параметры KNN:", grid_search_knn.best_params_)
print("Лучший F1-score (CV) KNN:", grid_search_knn.best_score_)

best_knn = grid_search_knn.best_estimator_
y_pred_best_knn = best_knn.predict(X_test)

print("Test Accuracy KNN:", accuracy_score(y_test, y_pred_best_knn))
print("Test F1-score KNN:", f1_score(y_test, y_pred_best_knn))
print("Test ROC AUC KNN:", roc_auc_score(y_test, best_knn.predict_proba(X_test)

```

Fitting 5 folds for each of 10 candidates, totalling 50 fits  
Лучшие параметры KNN: {'n\_neighbors': 11, 'weights': 'uniform'}  
Лучший F1-score (CV) KNN: 0.6197425486528603  
Test Accuracy KNN: 0.8176694845019061  
Test F1-score KNN: 0.6017378711078928  
Test ROC AUC KNN: 0.8552848738877858

## Сравнение моделей

```
In [21]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import accuracy_score, f1_score, roc_auc_score

# Baseline значения
baseline_metrics = {
    'Gradient Boosting': [0.8596, 0.6838, 0.9158],
    'Random Forest': [0.8424, 0.6568, 0.8961],
    'Logistic Regression': [0.8410, 0.6550, 0.8900],
    'Decision Tree': [0.8037, 0.6143, 0.8479],
    'KNN': [0.8013, 0.6016, 0.8592]
}

# Оптимизированные метрики (замени значениями, если уже обучил)
optimized_metrics = {
    'Gradient Boosting': [
        accuracy_score(y_test, y_pred_best_gb),
        f1_score(y_test, y_pred_best_gb),
        roc_auc_score(y_test, best_gb.predict_proba(X_test)[:,-1])
    ],
    'Random Forest': [
        accuracy_score(y_test, y_pred_best_rf),
        f1_score(y_test, y_pred_best_rf),
        roc_auc_score(y_test, best_rf.predict_proba(X_test)[:,-1])
    ],
    'Logistic Regression': [
        accuracy_score(y_test, y_pred_best_lr),
        f1_score(y_test, y_pred_best_lr),
        roc_auc_score(y_test, best_lr.predict_proba(X_test)[:,-1])
    ],
    'Decision Tree': [
        accuracy_score(y_test, y_pred_best_tree),
        f1_score(y_test, y_pred_best_tree),
        roc_auc_score(y_test, best_tree.predict_proba(X_test)[:,-1])
    ],
    'KNN': [
        accuracy_score(y_test, y_pred_best_knn),
        f1_score(y_test, y_pred_best_knn),
        roc_auc_score(y_test, best_knn.predict_proba(X_test)[:,-1])
    ]
}
```

```

# DataFrame для вывода
baseline_df = pd.DataFrame(baseline_metrics, index=['Accuracy', 'F1-score', 'R
optimized_df = pd.DataFrame(optimized_metrics, index=['Accuracy', 'F1-score',

# Объединённая таблица
comparison_df = pd.concat([
    baseline_df.add_suffix(' (Baseline)'),
    optimized_df.add_suffix(' (Optimized)')
], axis=1)

# Отображаем таблицу
display(comparison_df.style.background_gradient(cmap='Blues').format("{:.4f}")

# Строим 3 гистограммы (Accuracy, F1-score, ROC AUC)
metrics_names = ['Accuracy', 'F1-score', 'ROC AUC']
models = list(baseline_df.index)

fig, axes = plt.subplots(1, 3, figsize=(18, 6))

for idx, metric in enumerate(metrics_names):
    ax = axes[idx]
    baseline_values = baseline_df[metric]
    optimized_values = optimized_df[metric]

    x = np.arange(len(models))
    width = 0.35


    ax.bar(x - width/2, baseline_values, width, label='Baseline', color='#1f77
    ax.bar(x + width/2, optimized_values, width, label='Tuned', color='#ff7f0e

    ax.set_title(f'Сравнение {metric} (Baseline vs Tuned)')
    ax.set_ylabel(metric)
    ax.set_xticks(x)
    ax.set_xticklabels(models, rotation=45)
    ax.legend()
    ax.grid(axis='y', linestyle='--', alpha=0.7)

plt.tight_layout()
plt.show()

```

	Accuracy (Baseline)	F1-score (Baseline)	ROC AUC (Baseline)	Accuracy (Optimized)	F1-score (Optimized)	ROC AUC (Optimized)
<b>Gradient Boosting</b>	0.8596	0.6838	0.9158	0.8642	0.7040	0.9211
<b>Random Forest</b>	0.8424	0.6568	0.8961	0.8558	0.6794	0.9011
<b>Logistic Regression</b>	0.8410	0.6550	0.8900	0.8420	0.6528	0.8911
<b>Decision Tree</b>	0.8037	0.6143	0.8479	0.8507	0.6596	0.8911
<b>KNN</b>	0.8013	0.6016	0.8592	0.8177	0.6017	0.8511



## Выводы по результатам оптимизации моделей

В рамках этапа оптимизации гиперпараметров были рассмотрены все пять моделей, участвовавших в baseline-сравнении:

- Gradient Boosting
- Random Forest
- Logistic Regression
- Decision Tree
- K-Nearest Neighbors

Для каждой из моделей был проведён подбор гиперпараметров с использованием **GridSearchCV** и **5-кратной кросс-валидации** (  $cv=5$  ) по метрике **F1-score**, как наиболее подходящей для несбалансированной задачи бинарной классификации.

# Сравнение результатов (Baseline vs Optimized)

В результате подбора были достигнуты следующие улучшения:

- **Gradient Boosting** сохранил лидирующие позиции, показав наилучшие значения F1-score и ROC AUC. Оптимизация привела к незначительному, но стабильному приросту качества.
  - **Random Forest** также улучшил свои метрики, особенно по F1-score, за счёт более точной настройки глубины деревьев и количества признаков.
  - **Logistic Regression** показала небольшое улучшение после настройки параметра регуляризации `C`, что позволило лучше адаптироваться к дисбалансу классов.
  - **Decision Tree** и **KNN** остались наименее устойчивыми моделями, при этом оптимизация позволила немного повысить F1-score и снизить переобучение.
- 

## Общие выводы:

- **Оптимизация гиперпараметров оказывает положительное влияние на все модели**, особенно ансамблевые.
- **Gradient Boosting** остаётся наиболее надёжной моделью для данной задачи и рекомендован к использованию в качестве финального решения.
- Полученные улучшения подтверждаются как численно (таблицей метрик), так и визуально (ROC-кривыми, графиком обучения/валидации).